

Tema 2 - Metode Numerice

Facultatea de Automatică și Calculatoare
Universitatea Politehnică București

May 6, 2018

Cuprins

1	Introducere	3
1.1	Descompunerea valorilor singulare	3
2	Compresia imaginilor folosind DVS	4
2.1	Cerinta 1 [15p]	5
2.2	Cerinta 2 [20p]	5
3	Compresia imaginilor folosind analiza componentelor principale	6
3.1	Cerinta 3 [25p]	6
3.2	Cerinta 4 [15p]	7
3.3	Cerinta 5 [25p]	7
4	Observatii	8
5	Bibliografie	9

1 Introducere

În recunoasterea formelor, selectia și extragerea caracteristicilor reprezintă o alegere decisivă pentru proiectarea oricărui clasificator. Selectia caracteristicilor poate fi văzută și ca un proces de compresie de date, fiind similară cu o transformare liniară din spațiul inițial al observațiilor într-un spațiu cu mai puține dimensiuni. O astfel de transformare este necesară deoarece poate păstra o mare parte din informații (prin eliminarea informațiilor redundante sau a celor mai puțin semnificative) și permite aplicarea unor algoritmi eficienți doar într-un spațiu de dimensiuni reduse.

Cele mai multe transformări utilizate pentru selectia caracteristicilor sunt cele liniare, în timp ce transformările neliniare au o complexitate mai ridicată, sunt mai dificil de implementat, dar pot avea o eficiență mai mare asupra rezultatelor, exprimând mai bine dependența dintre formele observate și caracteristicile selectate ale acestor forme.

1.1 Descompunerea valorilor singulare

Fiind dată o matrice $A \in R^{m \times n}$, descompunerea valorilor singulare (DVS, în eng. singular value decomposition - SDV) ale matricei A este dată de factorizarea $A = USV^T$, unde:

1. $U \in R^{m \times m}$ este o matrice ortonormată
2. $S \in R^{m \times n}$ este o matrice diagonală
3. $V \in R^{n \times n}$ este o matrice ortonormată

Elementele de pe diagonală principală a lui S sunt întotdeauna numere reale nenegative ($s_{ii} \geq 0$ pentru $i = 1 : \min(m, n)$) și se numesc *valorile singulare* ale matricei A . Acestea sunt așezate în ordine descrescătoare, astfel încât $s_{11} \geq s_{22} \geq \dots \geq s_{rr} > s_{r+1, r+1} = \dots = s_{pp} = 0$, unde $p = \min(m, n)$.

Coloanele $u_j \in R^m$, $j = 1 : m$ ale lui U se numesc *vectori singulari stanga* ai matricei A . Coloanele $v_j \in R^n$, $j = 1 : n$ ale lui V se numesc *vectori singulari dreapta* ai matricei A .

De exemplu, pentru matricea:

$$A = \begin{bmatrix} 3 & 2 & 2 \\ 2 & 3 & -2 \end{bmatrix}$$

se obține următoarea descompunere a valorilor singulare:

$$A = USV^T = \begin{bmatrix} 1/\sqrt{2} & 1/\sqrt{2} \\ 1/\sqrt{2} & -1/\sqrt{2} \end{bmatrix} \begin{bmatrix} 5 & 0 & 0 \\ 0 & 3 & 0 \end{bmatrix} \begin{bmatrix} 1/\sqrt{2} & 1/\sqrt{2} & 0 \\ 1/\sqrt{18} & -1/\sqrt{18} & 4/\sqrt{18} \\ 2/3 & -2/3 & -1/3 \end{bmatrix}$$




Figura 1: Descompunerea valorilor singulare pentru matricea A de dimensiune $m \times n$, unde $m > n$.




Figura 2: Descompunerea valorilor singulare pentru matricea A de dimensiune $m \times n$, unde $n > m$, $S = \Sigma$, $V^t = V^*$.

2 Compresia imaginilor folosind DVS

Descompunerea reducia a valorilor singulare presupune descompunerea (factorizarea) matricei A astfel: $A \approx A_k = U_k S_k V_k^T$, unde $A_k \in R^{m \times n}$, $U_k \in R^{m \times k}$, $S_k \in R^{k \times k}$, $V_k^T \in R^{k \times n}$.

Intuitiv, descompunerea reducia a valorilor singulare semnifica eliminarea valorilor singulare nule sau a valorilor singulare nule si a celor de o valoare mica din matricea S (reprezentand informatia mai putin semnificativa). Acest lucru presupune si eliminarea coloanelor si a liniilor corespunzatoare acestor valori singulare din matricele U , respectiv din V (vezi Figura 3).

In cele ce urmeaza, presupunem ca matricea A reprezinta modelarea matematica pentru o imagine alb-negru clara si matricea A_k este modelarea matematica pentru o imagine alb-negru aproximativa a imaginii clare. Ambele imagini au dimensiune $m \times n$ pixeli. Fiecare element (i, j) din matricele A si A_k corespunde intensitatii de gri a pixelului (i, j) din imagine. Prin urmare, elementele matricelor A si A_k au valori cuprinse intre 0 (corespunzatoare culorii negre) si 255 (corespunzatoare culorii albe).




Figura 3: Exemplu de descompunere reduca a valorilor singulare pentru matricea A $m \times n$ dimensională, $m > n$. Aceasta descompunere presupune eliminarea porțiunilor hasurate în alb din matricele U , S , respectiv V^t . Porțiunile hasurate în gri (notate U_k , S_k , respectiv V_k^t) din matricele U , S , respectiv V se vor păstra. Astfel, matricea A_k va aproxima matricea inițială A .

2.1 Cerinta 1 [15p]

În cadrul acestei cerințe, va trebui să scrieți o funcție Octave pentru comprimarea unei imagini folosind descompunerea reduca a valorilor singulare. Semnatura funcției este: `function A_k = cerinta1 (image, k)`, unde *image* reprezintă calea către imagine și k numărul de valori singulare. Funcția trebuie să întoarcă matricea A_k având semnificația de mai sus.

2.2 Cerinta 2 [20p]

Scrieți o funcție pentru a obține următoarele 4 grafice pentru o imagine:

- folosind descompunerea valorilor singulare:

1. reprezentați grafic toate *valorile singulare* ale matricei A în ordine descrescătoare.

- folosind descompunerea reduca a valorilor singulare (cerinta 1), pentru diferite valori ale lui k (de exemplu, k poate fi [1:19 20:20:99 100:30:min(m,n)]):

2. reprezentați grafic k (pe axa OX) și *informația* dată de primele k valori singulare (pe axa OY) calculată după formula:

$$\frac{\sum_{i=1}^k s_{ii}}{\sum_{i=1}^{\min(m,n)} s_{ii}}$$

3. reprezentati grafic k (pe axa OX) si *eroarea aproximarii* pentru matricea A (pe axa OY) calculata dupa formula:

$$\frac{\sum_{i=1}^m \sum_{j=1}^n (A(i, j) - A_k(i, j))^2}{m * n}$$

4. reprezentati grafic k (pe axa OX) si *rata de compresie* a datelor (pe axa OY) calculata dupa formula:

$$\frac{m * k + n * k + k}{m * n}$$

Justificare formula: Pentru obtinerea imaginii aproximative avem nevoie sa memoram doar matricele U_k, V_k^T si primele k elemente de pe diagonala principala a matricei S_k . In total, $m*k+n*k+k$ elemente trebuie memorate. Astfel, stocarea acestora ocupa memorie mai putina comparativ cu memoria ocupata de matricea A pentru $m*n$ elemente. Tinant cont de faptul ca cea mai mare parte din informatia continuta in matrice este data de primele valori singulare, compresia datelor folosind descompunerea reduisa a valorilor singulare permite o economisire de memorie.

Semnatura functiei este *function cerinta2()*.

3 Compresia imaginilor folosind analiza componentelor principale

Scopul analizei componentelor principale (in eng. principal component analysis - PCA), este de a transforma date de tipul $A = [a_1, a_2, \dots, a_n]$, dintr-un spatiu dimensional R^m intr-un spatiu dimensional R^k , unde $a_i \in R^m$ si $k < m$. Acest spatiu este dat de cele k componente principale (PC). Componentele principale sunt ortonormale, necorelate si reprezinta directia variatiei maxime. Prima componenta principala reprezinta directia variatiei maxime a datelor, urmand ca urmatoarele componente principale sa aduca variatii din ce in ce mai mici.

3.1 Cerinta 3 [25p]

Urmatorul algoritim calculeaza componentele principale folosind metoda DVS: Fiind data o matrice $A = [a_1, a_2, \dots, a_n] \in R^{m*n}$, unde $a_j \in R^{m*1}, j = 1 : n$:

1. Se calculeaza urmatoarea medie pentru fiecare vector $a_i \in R^{1*n}, i = 1 : m$:

$$\mu_i = \frac{\sum_{j=1}^n a_i(j)}{n}.$$
2. Se actualizeaza vectorii $a_i \in R^{1*n}, i = 1 : m$ astfel: $a_i = a_i - \mu_i$.
3. Se construiesc matricea $Z = \frac{A^T}{\sqrt{n-1}}, Z \in R^{n*m}$.
4. Se calculeaza DVS pentru matricea Z : $Z = USV^T$.

5. Spatiul k-dimensional al componentelor principale (notat cu W) este dat de primele k coloane din matricea $V = [v_1, v_2, \dots, v_m] \in R^{m \times m}$: $W = [v_1, v_2, \dots, v_k]$ (v_1 este prima PC, v_2 este a doua PC s.a.m.d).
6. Se calculeaza proiectia lui A in spatiul componentelor principale, adica matricea $Y = W^T A$.
7. Se aproximeaza matricea initiala astfel: $A_k = WY + \mu$, unde $\mu \in R^{m \times 1}$ iar elementele μ_i ale vectorului μ au fost calculate la pasul 1.

Funcția Octave care implementeaza acesta cerinta este: `function [A_k S] = cerinta3(image, k)`, unde *image* reprezinta calea catre imagine si *k* numarul de componente principale. Funcția intoarce matricele A_k si S cu semnificatia prezentata in acest algoritm.

3.2 Cerinta 4 [15p]

Componentele principale se pot calcula folosind si un algoritm bazat pe matricea de covarianța. Pasii pentru acest algoritm sunt:

Fiind data o matrice $A = [a_1, a_2, \dots, a_n] \in R^{m \times n}$, unde $a_j \in R^{m \times 1}, j = 1 : n$:

- Pasii 1-2 sunt aceeasi ca la cerinta 3.
- Se construiesc matricea de covarianța $Z = \frac{A * A^T}{n-1}, Z \in R^{m \times m}$.
- Se aplica funcția *eig* asupra matricei Z: $[V S] = eig(Z)$.
- Spatiul k-dimensional al componentelor principale (notat cu W) este dat de primele k coloane din matricea $V = [v_1, v_2, \dots, v_m] \in R^{m \times m}$: $W = [v_1, v_2, \dots, v_k]$.
- Pasii 6-7 sunt aceeasi ca la cerinta 3.

Funcția Octave care implementeaza acesta cerinta este: `function [A_k S] = cerinta4(image, k)`, unde *image* reprezinta calea catre imagine si *k* numarul de componente principale. Funcția intoarce matricele A_k si S cu semnificatia prezentata in acest algoritm.

3.3 Cerinta 5 [25p]

Folosind *cerinta 3*, scrieti o funcție pentru a obtine urmatoarele 4 grafice pentru o imagine:

1. reprezentati grafic vectorul $diag(S)$.

Pentru diferite valori ale lui k (de exemplu, k poate fi [1:19 20:20:99 100:30:min(m,n)]):

2. reprezentati grafic k (pe axa OX) si *informatia* data de primele k valori singulare (pe axa OY) calculata dupa formula:

$$\frac{\sum_{i=1}^k s_{ii}}{\sum_{i=1}^{\min(m,n)} s_{ii}}$$

3. reprezentati grafic k (pe axa OX) si *eroarea aproximarii* pentru matricea A (pe axa OY) calculata dupa formula:

$$\frac{\sum_{i=1}^m \sum_{j=1}^n (A(i,j) - A_k(i,j))^2}{m * n}$$

4. reprezentati grafic k (pe axa OX) si *rata de compresie* a datelor (pe axa OY) calculata dupa formula:

$$\frac{2 * k + 1}{n}$$

Justificare formula: Matricea A are dimensiunea $m * n$. Pentru reconstruc-tia matricei A este nevoie de W , Y si μ avand fiecare m linii si k , k coloane, respectiv 1 coloana. Prin urmare, numarul de coloane m -dimensionale de stocat a fost redus de la n la $2*k+1$.

Semnatura functiei este *function cerinta5()*.

4 Observatii

1. Imaginile de testare sunt doar in format alb-negru. Pentru a citi o imagine in program folositi functiile *imread* si *double* din Octave.
2. Pentru vizualizarea imaginilor pe care le obtineti folositi functiile *imshow* si *uint8* din Octave. Aceasta cerinta nu este obligatorie (checker-ul verifica doar datele returnate de functiile obligatorii), dar va ajuta sa observati diferentele pe imaginile modificate.
3. Puteti sa definiti functii auxiliare in cazul in care aveti nevoie de acestea.
4. In rezolvarea temei, aveti voie sa folositi functiile din Octave (inclusiv functiile *svd* si *eig*) cu o singura restrictie: NU folositi functia *princomp* din Octave.
5. Fisierul *Readme* (cu extensia *.pdf*) va contine doua parti: graficele si interpretarea rezultatelor obtinute la cerintele 2 si 5. Cerintele 2 si 5 le testati pentru oricare 2 imagini aflate in directorul *in* din checker. Pentru a desena un grafic continand mai multe subgrafice se foloseste functia *subplot*. Tot in *Readme* puteti pune si poze cu imaginile obtinute la cerintele 2 si 5 daca considerati ca va ajuta la interpretarea rezultatelor.

6. Checker-ul face testarea automata doar a cerintelor 1, 3 si 4, cerintele 2 si 5 le vom corecta manual.
7. Arhiva *.zip* trebuie sa includa DOAR functiile pe care voi le scrieti, nu includeti in arhiva altceva.

5 Bibliografie

1. Richard L.Burden, J. Douglas Faires, *Numerical Analysis*, Editia 9, Subcapitolul 9.6
2. http://www.cs.utexas.edu/users/inderjit/public_papers/HLA_SVD.pdf
3. https://en.wikipedia.org/wiki/Principal_component_analysis